

# Conditional Random Fields

BrightHush

2014 年 12 月 1 日

## 目录

### 1 Model

#### 1.1 Linear Chain CRFs

在介绍linear chain conditional random fields之前，首先介绍条件概率 $p(y|x)$ ，这个条件可以通过HMM中的联合概率得到。重点在于条件分布实际上是使用特定特征函数的条件随机场。

在这里我们首先重写HMM联合概率公式，当然是以更加通用的方式重写该公式，其中需要注意的是在HMM中变量 $\mathbf{y}$ 表示状态序列， $\mathbf{x}$ 表示观察序列，因此注意下面公式中各变量的含义及公式本身表示的意义。

$$p(\mathbf{y}, \mathbf{x}) = \frac{1}{Z} \prod_{t=1}^T \exp \left( \sum_{i,j \in S} \theta_{ij} 1_{y_t=i} 1_{y_{t-1}=j} + \sum_{i \in S} \sum_{o \in O} \mu_{oi} 1_{y_t=i} 1_{x_t=o} \right) \quad (1)$$

其中 $\theta = (\theta_{ij}, \mu_{oi})$ 是该分布的实数参数， $Z$ 是归一化参数来保证最后的概率之和为1。上式可以认为是HMM模型的一种泛化，通常的HMM可以当成该模型的一个特例。当 $\theta_{ij} = \log p(y' = i | y = j)$ ,  $\mu_{oi} = \log p(x = o | y = i)$ 的时候，那么就是通常我们所熟知的HMM模型了。

通过引入 $feature\ functions$ ，我们可以更加紧密的表示上面的公式。每一个特征函数的形式为 $y_k(y_t, y_{t-1}, x_t)$ 。为了能完整的表达上面的概率公式，需要有一个特征 $f_{ij}(y, y', x) = 1_{y=i} 1_{y'=j}$ 表示每一个状态转移 $(i, j)$ ，需要有一个特征 $f_{io}(y, y', x) = 1_{y=i} 1_{x=o}$ 表示状态-观察值对 $(i, o)$ 。我们使用 $f_k$ 表示特征函数， $f_k$ 需要遍历所有的 $f_{ij}$ 和所有的 $f_{io}$ 。因此我们可以写作下面的方

式:

$$p(\mathbf{y}, \mathbf{x}) = \frac{1}{Z} \prod_{t=1}^T \exp\left(\sum_{k=1}^K \theta_k f_k(y_t, y_{t-1}, x_t)\right) \quad (2)$$

最后一步, 对于给定观察序列 $\mathbf{x}$ , 求状态序列 $\mathbf{y}$ 的条件概率如下:

$$p(y|x) = \frac{p(y, x)}{\sum_{y'} p(y', x)} \quad (3)$$

$$= \frac{\prod_{t=1}^T \exp\left(\sum_{k=1}^K \theta_k f_k(y_t, y_{t-1}, x_t)\right)}{\sum_{y'} \prod_{t=1}^T \exp\left(\sum_{k=1}^K \theta_k f_k(y'_t, y'_{t-1}, x_t)\right)} \quad (4)$$

这是一个比较特别的linear chain CRF, 因为仅仅考虑了单独当前词对应的特征。而对于其他很多的linear chain CRF 会使用丰富的特征, 例如当前词的前缀、后缀, 或者是周围词的等等。如果我们用更加通用的特征函数来替换当前词相关的特征函数, 那么我们可以得到更加通用的linear chain CRF:

**Definition :** Let  $Y, X$  be random vectors. Then a *linear chain conditional random field* is a distribution  $p(\mathbf{y}|\mathbf{x})$  that takes the form:

$$p(\mathbf{y}|\mathbf{x}) = \frac{1}{Z(\mathbf{x})} \prod_{t=1}^T \exp\left(\sum_{k=1}^K \theta_k f_k(y_t, y_{t-1}, x_t)\right) \quad (5)$$

where  $Z(x)$  is an instance specific normalization function

$$Z(\mathbf{x}) = \sum_{\mathbf{y}} \prod_{t=1}^T \exp\left(\sum_{k=1}^K \theta_k f_k(y_t, y_{t-1}, x_t)\right) \quad (6)$$

通过以上我们可以看到, 如果对联合概率 $p(y, x)$ 按照HMM的方式进行分解, 那么相应的条件概率 $p(y|x)$  就是一个线性的crf模型。举例来说, 在HMM中, 通过状态 $i$ 转到状态 $j$ 会得到相同的分数 $\log p(y_t = j | y_{t-1} = i)$ , 而没有参考输入。在CRF中, 我们可以令 $(i, j)$ 转移得到的分数依赖于当前的观察序列, 通过增加一个特征 $1_{y_t=j} 1_{y_{t-1}=i} 1_{x_t=0}$ 。使用这种特征的CRF模型被广泛的应用在文本领域。

最后, 需要注意的是归一化常量 $Z(x)$ 是对所有的可能的状态序列进行求和, 这是一个指数级增长的数量。然而, 这个可以被forward-backward算法高效的计算。

## 2 References