

HMM-MEMM-CRF

Bright

2015 年 6 月 1 日

目录

1	Why this article	1
2	Hidden Markov Model	1
3	Maximum Entropy Markov Model	2
4	Conditional Random Field	3
5	References	3

1 Why this article

在做序列标注的时候，我们首先想到要用的方法是CRF，因为这个是目前来说效果最好的方法。但是我们知道，在CRF之前，HMM和MEMM同样可以用来做序列标注，为什么前两者的效果不如CRF呢？下面我们就从建模的角度来看看为什么会这样。

2 Hidden Markov Model

在隐马尔科夫模型中，我们知道存在两种矩阵，一种是状态转移矩阵，我们用 A 表示；一种是发射矩阵，表示从一个隐藏状态到一个观察值的概率，我们用 B 表示。

下面的讨论中，我们约定几个变量的使用。输出变量用 x 表示，即 $x = \{x_1, x_2, \dots, x_T\}$ ，每一个 x_i 的取值为 $V = \{v_1, v_2, \dots, v_{|V|}\}$ 之一，状态变量用 $z = \{z_1, z_2, \dots, z_T\}$ 表示，每个状态的取值为 $S = \{s_1, s_2, \dots, s_{|S|}\}$ 之一。

HMM的建模过程中，存在两个假设：

- a. 一阶马尔科夫假设，即 $p(z_i|z_{i-1}, \dots, z_1) = p(z_i|z_{i-1})$ ，当前状态的出现，仅仅依赖于前一个状态
- b. 输出独立性假设，即 $p(x_i|x_{i-1}, \dots, x_1, z_i, \dots, z_1) = p(x_i|z_i)$ ，即当前输出仅仅依赖于当前状态

于是对于一个已知的状态序列和观察序列，我们很容易表示其联合概率如下

$$p(x, z) = p(x|z)p(z) \quad (1)$$

$$= p(x_1, \dots, x_T|z)p(z_1, \dots, z_T) \quad (2)$$

$$= \prod_{i=1}^T p(x_i|z_i) \prod_{i=1}^T p(z_i|z_{i-1}) \quad (3)$$

$$= \prod_{i=1}^T p(x_i|z_i)p(z_i|z_{i-1}) \quad (4)$$

从上面的公式我们可以看到，在HMM中，我们建模的是联合概率，并且在序列中，每一时刻的观察值是相互独立的，并且仅仅依赖于当前时刻的状态。因此这里的假设是非常强的，而且建模联合概率通常也不是我们所希望的，因此HMM的局限性比较大。

3 Maximum Entropy Markov Model

最大熵模型，想必大家都有所耳闻，MEMM只是将最大熵模型扩展到了Markov链上。最大熵模型的思想是，在满足约束条件的基础上，我们保证熵最大，也就是我们并不对概率模型做任何的假设。

在MEMM中，其建模的是条件概率，并且根据Markov假设的阶数不同，建模也会有所不同。下面以Trigram MEMMs为例，也就是说，当前的

输出，仅仅和前两个输出有关。

$$p(y_1, \dots, y_T | x_1, \dots, x_T) = \prod_{i=1}^T p(y_i | x_1, \dots, x_T, y_{i-2}, y_{i-1}) \quad (5)$$

$$p(y_i | x_1, \dots, x_T, y_{i-2}, y_{i-1}) = \frac{\exp(\sum_{k=1}^K \theta_k f_k(x_1, \dots, x_T, y_{i-2}, y_{i-1}, y_i))}{\sum_y \exp(\sum_{k=1}^K \theta_k f_k(x_1, \dots, x_T, y_{i-2}, y_{i-1}, y))} \quad (6)$$

从上面的公式我们可以看到，当前输出的 y_i 不仅依赖于所有的 x_i ，还依赖于前两阶的 (y_{i-2}, y_{i-1}) ，那么任意特征函数的输入就可以是 y_i 所依赖的内容。

4 Conditional Random Field

在CRF中建模的也是条件概率，这个时候 $p(y|x)$ 并不是对单个的点进行连乘，CRF中 $p(y|x)$ 表示的就是归一化的概率。对于给定观察序列 \mathbf{x} ，求状态序列 \mathbf{y} 的条件概率如下：

$$p(y|x) = \frac{p(y, x)}{\sum_{y'} p(y', x)} \quad (7)$$

$$= \frac{\prod_{t=1}^T \exp(\sum_{k=1}^K \theta_k f_k(y_t, y_{t-1}, x))}{\sum_{y'} \prod_{t=1}^T \exp(\sum_{k=1}^K \theta_k f_k(y'_t, y'_{t-1}, x))} \quad (8)$$

于是我们知道在CRF中的 $p(y|x)$ 依赖于整体归一化的结果，而不是像MEMM中依赖于逐点的点进行连乘。所以CRF考虑的更加像是全局最优解，因此CRF能解决像MEMM的转移偏置的问题，当然也比HMM更加的通用。

5 References

1. Hidden Markov Models Fundamentals, Daniel Ramage, CS229 Section Notes, Stanford University.
2. Chapter 8, MEMMS(Log-Linear Tagging Models)