

Latent Dirichlet Allocation

BrightHush

2015 年 1 月 27 日

目录

1	LDA with Gibbs Sampling	1
1.1	Basic Distribution Knowledge	1
1.2	Parameters Table	2
1.3	Mixture modelling	3
1.4	Generative model	3
1.5	Likelihoods	4
1.6	Inference via Gibbs Sampling	4
1.7	The collapsed LDA Gibbs Sampler	4
2	References	7

1 LDA with Gibbs Sampling

1.1 Basic Distribution Knowledge

Gamma function 阶乘的扩展, 如果 n 是整数, 那么:

$$\Gamma(n) = (n-1)! \quad (1)$$

gamma function 对负整数和0没有定义之外, 对于实部为整数的复数, 其定义为一个积分:

$$\Gamma(t) = \int_0^{\infty} x^{t-1} e^{-x} dx \quad (2)$$

Dirichlet dsistribution 有 $K(K \geq 2)$ 个参数, 表示为 $\alpha = (\alpha_1, \alpha_2, \dots, \alpha_K)$, 其中 $\alpha_i > 0$, 有 K 个变量分别表示为 (x_1, x_2, \dots, x_K) , 其中 $x_i \in [0, 1]$, 并且 $\sum_{i=1}^K x_i = 1$ 。其概率密度函数可以表示为:

$$f(x_1, \dots, x_K; \alpha) = \frac{1}{B(\alpha)} \prod_{i=1}^K x_i^{\alpha_i-1} \quad (3)$$

$$\sum_{i=1}^K x_i = 1 \quad (4)$$

$$B(\alpha) = \frac{\prod_{k=1}^K \Gamma(\alpha_k)}{\Gamma(\sum_{k=1}^K \alpha_k)} \quad (5)$$

其中各变量的期望和最大值可以表示如下:

$$E[x_i] = \frac{\alpha_i}{\sum_{k=1}^K \alpha_k} \quad (6)$$

$$x_i = \frac{\alpha_i - 1}{\sum_{k=1}^K \alpha_k - K} \quad Mode \quad (7)$$

Dirichlet 分布的边缘分布是Beta分布, 可以表示如下:

$$x_i \sim Beta(\alpha_i, \sum_{k=1}^K \alpha_k - \alpha_i) \quad (8)$$

Dirichlet分布有一个特殊的情况, 就是**Symmetric Dirichlet Distribution**, 所谓对称Dirichlet分布就是参数 α 的各个分量相同, 也就是各个 α_i 具有相同的值。通常情况下, 如果先验知识中并没有关于一个分量比另外一个分量更重要的信息, 那么Symmetric Dirichlet Distribution 通常被作为先验分布。Symmetric Dirichlet Distribution 可以表示如下:

$$f(x_1, \dots, x_K; \alpha) = \frac{\Gamma(K\alpha)}{\Gamma(\alpha)^K} \prod_{k=1}^K x_k^{\alpha-1} \quad (9)$$

1.2 Parameters Table

$p(w = t|z = k)$: a multinomial distribution over terms that corresponding one of the latent topics $z=k$.

$p(t|z = k) = \vec{\varphi}_k$: term distribution for each topic k .

$p(z|d = m) = \vec{\vartheta}_m$: topic distribution for each document m .

$\underline{\phi} = (\vec{\varphi}_k)_{k=1}^K$: parameter set.

$\underline{\theta} = \left(\vec{\vartheta}_m \right)_{m=1}^M$: parameter set.

M : number of document to generate (constant scalar).

K : number of topics (constant scalar).

V : number of terms t in vocabulary (constant scalar).

$\vec{\alpha}$: hyper parameter of Dirichlet distribution which is prior distribution of doc-topic multinomial distribution.

$\vec{\beta}$: hyper parameter of Dirichlet distribution which is prior of topic-term multinomial distribution.

N_m : length of document m .

$z_{m,n}$: topic indicator for the n th word in document m .

$w_{m,n}$: term indicator for the n th word in document m .

1.3 Mixture modelling

LDA是一种混合模型，其使用一组子分布加权来建模观察到的数据，其实也就是使用主题分布作为分量，那么每个词的概率可以表示为：

$$p(t = w) = \sum_{k=1}^K p(t = w | z = k) p(z = k), \quad \sum_{k=1}^K p(z = k) = 1 \quad (10)$$

但是LDA中的主题分布并不是全局一样的，而是基于每一篇文档主题分布情况是不同的，于是在LDA中有两组目标需要推断（1）主题 k 下的词分布 $p(t|z = k) = \vec{\varphi}_k$ 和（2）文档 m 下的主题分布 $p(z|d = m) = \vec{\vartheta}_m$ 。

1.4 Generative model

为了获得推断策略，LDA生成模型的过程可以被理解为如下内容：对于每一篇文档，首先生成主题分布 $\vec{\vartheta}_m$ ，对于文档中的每个词，根据 $\vec{\vartheta}_m$ 各主题占比分布对每个词选择一个主题，用 $z_{m,n}$ 表示，那么根据这个词所在主题 $z_{m,n}$ 的 $\vec{\varphi}_{z_{m,n}}$ 来生成这个词。需要注意的是 $\vec{\varphi}_k$ 在整个语料中只会生成一次。

1.5 Likelihoods

对于整个语料集，如果每一个词都被赋予了主题标记 $z_{m,n}$ ，那么一篇文档的似然可以表示为：

$$L(\vec{w}_m, \vec{z}_m, \vec{\vartheta}_m, \underline{\phi}) = \prod_{n=1}^{N_m} p(w_{m,n} | \vec{\varphi}_{z_{m,n}}) p(z_{m,n} | \vec{\vartheta}_m) p(\vec{\vartheta}_m | \underline{\alpha}) p(\underline{\phi} | \underline{\beta}) \quad (11)$$

对于一篇文档中的一个词，其产生的概率可以表示为(57)(11)：

$$p(w_{m,n} = t | \vec{\vartheta}_m, \underline{\phi}) = \sum_{k=1}^K p(w_{m,n} = t | \vec{\varphi}_k) \cdot p(z_{m,n} = k | \vec{\vartheta}_m) \quad (12)$$

对于语料 $W = (\vec{w}_m)_{m=1}^M$ ，每篇文档的生成是独立的，每篇文档中的每个词生成过程也是独立的，所以语料的似然可以表示为(58)(12)：

$$L = p(W | \underline{\theta}, \underline{\phi}) = \prod_{m=1}^M p(\vec{w}_m | \vec{\vartheta}_m, \underline{\phi}) = \prod_{m=1}^M \prod_{n=1}^{N_m} p(w_{m,n} | \vec{\vartheta}_m, \underline{\phi}) \quad (13)$$

1.6 Inference via Gibbs Sampling

对于包含隐含变量 \vec{z} ，其后验概率 $p(\vec{z} | \vec{x})$ 通常是比较需要的分布，对于这样包含隐含变量模型的通用Gibbs sampler的公式可以表示如下(60)(13)公式所示：

$$p(z_i | \vec{z}_{-i}, \vec{x}) = \frac{p(\vec{z}, \vec{x})}{p(\vec{z}_{-i}, \vec{x})} \quad (14)$$

$$= \frac{p(\vec{z}, \vec{x})}{\int_{\mathcal{Z}} p(\vec{z}, \vec{x}) dz_i} \quad (15)$$

其中分母如果是对离散变量，那么可以改为对离散变量求和。按照Gibbs Sampling的思路，不断根据分量的条件概率进行采样，假设我们每次采样得到的样本为 $\vec{z}_r, r \in [1, R]$ ，如果采样次数足够多的话，那么隐含变量的后验概率可以表示为(61)(15)：

$$p(\vec{z} | \vec{x}) \approx \frac{1}{R} \sum_{r=1}^R \delta(\vec{z} - \vec{z}_r) \quad (16)$$

其中 $\delta(\vec{u}) = 1$ if $\vec{u} = 0$; 0 otherwise。

1.7 The collapsed LDA Gibbs Sampler

为了设计出LDA的Gibbs Sampler, 我们使用上面提到的隐含变量方法, 在我们的模型中, 隐含变量是 $z_{m,n}$, 也就是语料中词 $w_{m,n}$ 相对应的主题。通过对 $z_{m,n}$ and $w_{m,n}$ 进行统计, 可以得到其他参数的情况。

现在我们推断的目标是 $p(\vec{z}|\vec{w})$, 也就是每个词对应的主题情况, 如(62)(16)所示:

$$p(\vec{z}|\vec{w}) = \frac{p(\vec{z}, \vec{w})}{p(\vec{w})} = \frac{\prod_{i=1}^W p(z_i, w_i)}{\prod_{i=1}^W \sum_{k=1}^K p(z_i = k, w_i)} \quad (17)$$

由于上式中的分母计算量比较大, 那么这个时候Gibbs Sampling派上用场了, 为了仿真 $p(\vec{z}|\vec{w})$, 我们根据 $p(z_i|\vec{z}_{-i}, \vec{w})$ 进行Markov Chain进行Gibbs Sampling。根据公式(60)(13), 需要知道联合分布概率。

Joint Distribution. LDA中的联合分布可以分解为(63)(17):

$$p(\vec{w}, \vec{z}|\vec{\alpha}, \vec{\beta}) = p(\vec{w}|\vec{z}, \vec{\beta})p(\vec{z}|\vec{\alpha}) \quad (18)$$

等式(17)右边第一项可以表示为(64)(18):

$$p(\vec{w}|\vec{z}, \underline{\phi}) = \prod_{i=1}^W p(w_i|z_i) = \prod_{i=1}^W \varphi_{z_i, w_i} \quad (19)$$

上式是表示每个词从独立的多项分布中产生, 我们可以将上面的成绩拆成两项, 第一项按照主题乘积, 第二项按照词汇表乘积, 于是可以表示为(65)(19):

$$p(\vec{w}|\vec{z}, \underline{\phi}) = \prod_{k=1}^K \prod_{i: z_i=k} p(w_i = t|z_i = k) = \prod_{k=1}^K \prod_{t=1}^V \varphi_{k,t}^{n_k^{(t)}} \quad (20)$$

其中 $n_k^{(t)}$ 表示词t在主题k下出现的次数。

上式表示的是在一组确定的 ϕ 参数下词出现的条件概率, 我们知道 ϕ 中的参数是有Dirichlet先验的, 因此将上式对 ϕ 进行积分或者累加, 那么就能求得在超参 β 下的词条件概率:

$$p(\vec{w}|\vec{z}, \vec{\beta}) = \int p(\vec{w}|\vec{z}, \underline{\phi})p(\underline{\phi}|\vec{\beta})d\underline{\phi} \quad (21)$$

$$= \prod_{z=1}^K \frac{\Delta(\vec{n}_z + \vec{\beta})}{\Delta(\vec{\beta})}, \vec{n}_z = (n_z^{(t)})_{t=1}^V \quad (22)$$

同理按照 $p(\vec{w}|\vec{z}, \vec{\beta})$ 的推导，可以对 $p(\vec{z}|\alpha)$ 进行类似的推导。

$$p(\vec{z}|\theta) = \prod_{i=1}^W p(z_i|d_i) \quad (23)$$

$$= \prod_{m=1}^M \prod_{k=1}^K p(z_k = 1|d_i = m) \quad (24)$$

$$= \prod_{m=1}^M \prod_{k=1}^K \vartheta_{m,k}^{n_m^{(k)}} \quad (25)$$

其中 d_i 表示词 i 对应的文档， $n_m^{(k)}$ 表示在文档 m 中，topic k 出现的次数。上式对 θ 进行积分，可以得到：

$$p(\vec{z}|\vec{\alpha}) = \int p(\vec{z}|\theta)p(\theta|\vec{\alpha})d\theta \quad (26)$$

$$= \prod_{m=1}^M \frac{\Delta(\vec{n}_m + \vec{\alpha})}{\Delta(\vec{\alpha})}, \vec{n}_m = (n_m^{(k)})_{k=1}^K \quad (27)$$

于是可以得到主题和词的联合分部表示为：

$$p(\vec{w}, \vec{z}|\vec{\alpha}, \vec{\beta}) = \prod_{z=1}^K \frac{\Delta(\vec{n}_z + \vec{\beta})}{\Delta(\vec{\beta})} \prod_{m=1}^M \frac{\Delta(\vec{n}_m + \vec{\alpha})}{\Delta(\vec{\alpha})} \quad (28)$$

Full Conditional.根据联合概率分布，对于一个词 $i = (m, n)$ 我们可以得到其条件概率，也就是Gibbs Sampler采样一个隐含变量的条件概率，如式子(74,78)(28,29)：

$$p(z_i = k|\vec{z}_{-i}, \vec{w}) = \frac{p(\vec{w}, \vec{z})}{p(\vec{w}, \vec{z}_{-i})} = \frac{p(\vec{w}|\vec{z})}{p(\vec{w}_{-i}|\vec{z}_{-i})p(w_i)} \cdot \frac{p(\vec{z})}{p(\vec{z}_{-i})} \quad (29)$$

$$\propto \frac{n_{k,-i}^{(t)} + \beta_t}{\sum_{t=1}^V n_{k,-i}^{(t)} + \beta_t} (n_{m,-i}^{(k)} + \alpha_k) \quad (30)$$

Multinomial Parameters.最终，我们需要求解多项分布的参数，这些参数用之前的参数集合 (θ, ϕ) 表示。根据这些参数的定义，以及结合Dirichlet先验，根据贝叶斯公式，我们可以得到多项分布参数的后验估计，如等式(79,80)(30,31)所示：

$$p(\vec{\vartheta}_m|\vec{z}_m, \vec{\alpha}) = \frac{1}{Z_{\vartheta_m}} \prod_{n=1}^{N_m} p(z_{m,n}|\vec{\vartheta}_m) \cdot p(\vec{\vartheta}|\vec{\alpha}) = Dir(\vec{\vartheta}_m|\vec{n}_m + \vec{\alpha}) \quad (31)$$

$$p(\vec{\varphi}_k|\vec{z}, \vec{w}, \vec{\beta}) = \frac{1}{Z_{\varphi_k}} \prod_{i:z_i=k} p(w_i|\vec{\varphi}_k) \cdot p(\vec{\varphi}_k|\vec{\beta}) = Dir(\vec{\varphi}_k|\vec{n}_k + \vec{\beta}) \quad (32)$$

上式中 \vec{n}_m 表示第 m 篇文档中观察到的topic出现次数， \vec{n}_k 则相应的表示在topic k 中各词对应观察到的次数。根据Dirichlet Distribution的期望计算

方法 $\langle Dir(\vec{\alpha}) \rangle = \frac{a_i}{\sum_i a_i}$, 那么根据(79,80) (30, 31), 可以计算得到下面的结果:

$$\varphi_{k,t} = \frac{n_k^{(t)} + \beta_t}{\sum_{t=1}^V n_k^{(t)} + \beta_t} \quad (33)$$

$$\vartheta_{m,k} = \frac{n_m^{(k)} + \alpha_k}{\sum_{k=1}^K n_m^{(k)} + \alpha_k} \quad (34)$$

2 References

1 Parameter estimation for text analysis.

<http://www.52nlp.cn/unconstrained-optimization-one>.