

# Latent Dirichlet Allocation

BrightHush

2015 年 1 月 25 日

## 目录

<b>1 LDA with Gibbs Sampling</b>	<b>1</b>
1.1 Parameters Table . . . . .	1
1.2 Likelihoods . . . . .	2
1.3 Inference via Gibbs Sampling . . . . .	2
1.4 The collapsed LDA Gibbs Sampler . . . . .	3
<b>2 References</b>	<b>5</b>

## 1 LDA with Gibbs Sampling

### 1.1 Parameters Table

$p(w = t|z = k)$  : a multinomial distribution over terms that corresponding one of the latent topics  $z=k$ .

$p(t|z = k) = \vec{\varphi}_k$  : term distribution for each topic  $k$ .

$p(z|d = m) = \vec{\vartheta}_m$  : topic distribution for each document  $m$ .

$\underline{\phi} = (\vec{\varphi}_k)_{k=1}^K$  : parameter set.

$\underline{\theta} = \left(\vec{\vartheta}_m\right)_{m=1}^M$  : parameter set.

$M$  : number of document to generate (constant scalar).

$K$  : number of topics (constant scalar).

$V$  : number of terms  $t$  in vocabulary (constant scalar).

$\vec{\alpha}$  : hyper parameter of Dirichlet distribution which is prior distribution of doc-topic multinomial distribution.

$\vec{\beta}$  : hyper parameter of Dirichlet distribution which is prior of topic-term multinomial distribution.

$N_m$  : length of document  $m$ .

$z_{m,n}$  : topic indicator for the  $n$ th word in document  $m$ .

$w_{m,n}$  : term indicator for the  $n$ th word in document  $m$ .

## 1.2 Likelihoods

对于一篇文档中的一个词，其产生的概率可以表示为(57)(1):

$$p(w_{m,n} = t | \vec{\vartheta}_m, \underline{\phi}) = \sum_{k=1}^K p(w_{m,n} = t | \vec{\varphi}_k) \cdot p(z_{m,n} = k | \vec{\vartheta}_m) \quad (1)$$

对于语料  $W = (\vec{w}_m)_{m=1}^M$ ，每篇文档的生成是独立的，每篇文档中的每个词生成过程也是独立的，所以语料的似然可以表示为(58)(2):

$$L = p(W | \underline{\theta}, \underline{\phi}) = \prod_{m=1}^M p(\vec{w}_m | \vec{\vartheta}_m, \underline{\phi}) = \prod_{m=1}^M \prod_{n=1}^{N_m} p(w_{m,n} | \vec{\vartheta}_m, \underline{\phi}) \quad (2)$$

## 1.3 Inference via Gibbs Sampling

对于包含隐含变量  $\vec{z}$ ，其后验概率  $p(\vec{z} | \vec{x})$  通常是比较需要的分布，对于这样包含隐含变量模型的通用 Gibbs sampler 的公式可以表示如下(60)(3)公式所示:

$$p(z_i | \vec{z}_{-i}, \vec{x}) = \frac{p(\vec{z}, \vec{x})}{p(\vec{z}_{-i}, \vec{x})} \quad (3)$$

$$= \frac{p(\vec{z}, \vec{x})}{\int_{\mathcal{Z}} p(\vec{z}, \vec{x}) dz_i} \quad (4)$$

其中分母如果是对离散变量，那么可以改为对离散变量求和。按照 Gibbs Sampling 的思路，不断根据分量的条件概率进行采样，假设我们每次采样

得到的样本为 $\vec{z}_r, r \in [1, R]$ , 如果采样次数足够多的话, 那么隐含变量的后验概率可以表示为(61)(5):

$$p(\vec{z}|\vec{x}) \approx \frac{1}{R} \sum_{r=1}^R \delta(\vec{z} - \vec{z}_r) \quad (5)$$

其中 $\delta(\vec{u}) = 1$  if  $\vec{u} = 0$ ; 0 otherwise.

#### 1.4 The collapsed LDA Gibbs Sampler

为了设计出LDA的Gibbs Sampler, 我们使用上面提到的隐含变量方法, 在我们的模型中, 隐含变量是 $z_{m,n}$ , 也就是语料中词 $w_{m,n}$ 相对应的主题。通过对 $z_{m,n}$  and  $w_{m,n}$ 进行统计, 可以得到其他参数的情况。

现在我们推断的目标是 $p(\vec{z}|\vec{w})$ , 也就是每个词对应的主题情况, 如(62)(6)所示:

$$p(\vec{z}|\vec{w}) = \frac{p(\vec{z}, \vec{w})}{p(\vec{w})} = \frac{\prod_{i=1}^W p(z_i, w_i)}{\prod_{i=1}^W \sum_{k=1}^K p(z_i = k, w_i)} \quad (6)$$

由于上式中的分母计算量比较大, 那么这个时候Gibbs Sampling派上用场了, 为了仿真 $p(\vec{z}|\vec{w})$ , 我们根据 $p(z_i|\vec{z}_{-i}, \vec{w})$ 进行Markov Chain进行Gibbs Sampling。根据公式(60)(3), 需要知道联合分布概率。

**Joint Distribution.** LDA中的联合分布可以分解为(63)(7):

$$p(\vec{w}, \vec{z}|\vec{\alpha}, \vec{\beta}) = p(\vec{w}|\vec{z}, \vec{\beta})p(\vec{z}|\vec{\alpha}) \quad (7)$$

等式(7)右边第一项可以表示为(64)(8):

$$p(\vec{w}|\vec{z}, \underline{\phi}) = \prod_{i=1}^W p(w_i|z_i) = \prod_{i=1}^W \varphi_{z_i, w_i} \quad (8)$$

上式是表示每个词从独立的多项分布中产生, 我们可以将上面的成绩拆成两项, 第一项按照主题乘积, 第二项按照词汇表乘积, 于是可以表示为(65)(9):

$$p(\vec{w}|\vec{z}, \underline{\phi}) = \prod_{k=1}^K \prod_{i: z_i=k} p(w_i = t|z_i = k) = \prod_{k=1}^K \prod_{t=1}^V \varphi_{k,t}^{n_k^{(t)}} \quad (9)$$

其中 $n_k^{(t)}$ 表示词t在主题k下出现的次数。

上式表示的是在一组确定的 $\phi$ 参数下词出现的条件概率, 我们知道 $\phi$ 中的参

数是有Dirichlet先验的，因此将上式对 $\phi$ 进行积分或者累加，那么就能求得在超参 $\beta$ 下的词条件概率：

$$p(\vec{w}|\vec{z}, \vec{\beta}) = \int p(\vec{w}|\vec{z}, \phi) p(\phi|\vec{\beta}) d\phi \quad (10)$$

$$= \prod_{z=1}^K \frac{\Delta(\vec{n}_z + \vec{\beta})}{\Delta(\vec{\beta})}, \vec{n}_z = (n_z^{(t)})_{t=1}^V \quad (11)$$

同理按照 $p(\vec{w}|\vec{z}, \vec{\beta})$ 的推导，可以对 $p(\vec{z}|\alpha)$ 进行类似的推导。

$$p(\vec{z}|\theta) = \prod_{i=1}^W p(z_i|d_i) \quad (12)$$

$$= \prod_{m=1}^M \prod_{k=1}^K p(z_k = 1|d_i = m) \quad (13)$$

$$= \prod_{m=1}^M \prod_{k=1}^K \vartheta_{m,k}^{n_m^{(k)}} \quad (14)$$

其中 $d_i$ 表示词 $i$ 对应的文档， $n_m^{(k)}$ 表示在文档 $m$ 中，topic  $k$ 出现的次数。上式对 $\theta$ 进行积分，可以得到：

$$p(\vec{z}|\vec{\alpha}) = \int p(\vec{z}|\theta) p(\theta|\vec{\alpha}) d\theta \quad (15)$$

$$= \prod_{m=1}^M \frac{\Delta(\vec{n}_m + \vec{\alpha})}{\Delta(\vec{\alpha})}, \vec{n}_m = (n_m^{(k)})_{k=1}^K \quad (16)$$

于是可以得到主题和词的联合分部表示为：

$$p(\vec{w}, \vec{z}|\vec{\alpha}, \vec{\beta}) = \prod_{z=1}^K \frac{\Delta(\vec{n}_z + \vec{\beta})}{\Delta(\vec{\beta})} \prod_{m=1}^M \frac{\Delta(\vec{n}_m + \vec{\alpha})}{\Delta(\vec{\alpha})} \quad (17)$$

**Full Conditional.**根据联合概率分布，对于一个词 $i = (m, n)$ 我们可以得到其条件概率，也就是Gibbs Sampler采样一个隐含变量的条件概率，如式子(74,78)(18,19)：

$$p(z_i = k|\vec{z}_{-i}, \vec{w}) = \frac{p(\vec{w}, \vec{z})}{p(\vec{w}, \vec{z}_{-i})} = \frac{p(\vec{w}|\vec{z})}{p(\vec{w}_{-i}|\vec{z}_{-i})p(w_i)} \cdot \frac{p(\vec{z})}{p(\vec{z}_{-i})} \quad (18)$$

$$\propto \frac{n_{k,-i}^{(t)} + \beta_t}{\sum_{t=1}^V n_{k,-i}^{(t)} + \beta_t} (n_{m,-i}^{(k)} + \alpha_k) \quad (19)$$

**Multinomial Parameters.**最终，我们需要求解多项分布的参数，这些参数用之前的参数集合 $(\theta, \phi)$ 表示。根据这些参数的定义，以及结合Dirichlet先验，根据贝叶斯公式，我们可以得到多项分布参数的后验估

计，如等式(79,80)(20,21)所示：

$$p(\vec{\vartheta}_m | \vec{z}_m, \vec{\alpha}) = \frac{1}{Z_{\vec{\vartheta}_m}} \prod_{n=1}^{N_m} p(z_{m,n} | \vec{\vartheta}_m) \cdot p(\vec{\vartheta} | \vec{\alpha}) = Dir(\vec{\vartheta}_m | \vec{n}_m + \vec{\alpha}) \quad (20)$$

$$p(\vec{\varphi}_k | \vec{z}, \vec{w}, \vec{\beta}) = \frac{1}{Z_{\varphi_k}} \prod_{i: z_i=k} p(w_i | \vec{\varphi}_k) \cdot p(\vec{\varphi}_k | \vec{\beta}) = Dir(\vec{\varphi}_k | \vec{n}_k + \vec{\beta}) \quad (21)$$

上式中 $\vec{n}_m$ 表示第m篇文档中观察到的topic出现次数， $\vec{n}_k$ 则相应的表示在topic k中各词对应观察到的次数。根据Dirichlet Distribution的期望计算方法 $\langle Dir(\vec{\alpha}) \rangle = \frac{a_i}{\sum_i a_i}$ ，那么根据(79,80) (20, 21)，可以计算得到下面的结果：

$$\varphi_{k,t} = \frac{n_k^{(t)} + \beta_t}{\sum_{t=1}^V n_k^{(t)} + \beta_t} \quad (22)$$

$$\vartheta_{m,k} = \frac{n_m^{(k)} + \alpha_k}{\sum_{k=1}^K n_m^{(k)} + \alpha_k} \quad (23)$$

## 2 References

1 Parameter estimation for text anaylsis.

<http://www.52nlp.cn/unconstrained-optimization-one>.