Latent Dirichlet Allocation

BrightHush

2015 年 1 月 28 日

目录

1 LDA with Gibbs Sampling

1.1 Basic Distribution Knowledge

Gamma function 阶乘的扩展，如果n是整数，那么：

$$\Gamma(n) = (n-1)! \tag{1}$$

gamma function 对负整数和0没有定义之外，对于实部为整数的复数，其定义为一个积分：

$$\Gamma(t) = \int_0^\infty x^{t-1} e^{-x} dx \tag{2}$$

Dirichlet dsistribution 有K($K \geq 2$)个参数，表示为$\alpha = (\alpha_1, \alpha_2, ..., \alpha_K)$，其中$\alpha_i > 0$，有K个变量分别表示为$(x_1, x_2, ..., x_K)$，其中$x_i \in [0, 1]$，并且$\sum_{i=1}^{K} x_i = 1$。其概率密度函数可以表示为：

$$f(x_1, ..., x_K; \alpha) = \frac{1}{B(\alpha)} \Pi_{i=1}^{K} x_i^{\alpha_i - 1} \tag{3}$$

$$\sum_{i=1}^{K} x_i = 1 \tag{4}$$

$$B(\alpha) = \frac{\Pi_{k=1}^{K} \Gamma(\alpha_i)}{\Gamma(\sum_{k=1}^{K} \alpha_i)} \tag{5}$$

为了和Parameter estimation for text analysis 一文中的记号表示一致，在下面的笔记中，$B(\alpha)$统一用$\Delta(\alpha)$来表示。其中各变量的期望和最大值可以表示如下：

$$E[x_i] = \frac{\alpha_i}{\sum_{k=1}^{K} \alpha_k} \tag{6}$$

$$x_i = \frac{\alpha_i - 1}{\sum_{k=1}^{K} \alpha_i - K} \quad Mode \tag{7}$$

Dirichlet 分布的边缘分布是Beta分布，可以表示如下：

$$x_i \sim Beta(\alpha_i, \sum_{k=1}^{K} \alpha_k - \alpha_i) \tag{8}$$

Dirichlet分布有一个特殊的情况，就是**Symmetric Dirichlet Distribution**，所谓对称Dirichlet分布就是参数α的各个分量相同，也就是各个α_i具有相同的值。通常情况下，如果先验知识中并没有关于一个分量比另外一个分量更重要的信息，那么Symmetric Dirichlet Distribution 通常被作为先验分布。Symmetric Dirichlet Distribution 可以表示如下：

$$f(x_1, \cdots, x_K; \alpha) = \frac{\Gamma(K\alpha)}{\Gamma(\alpha)^K} \Pi_{k=1}^{K} x_k^{\alpha - 1} \tag{9}$$

1.2 Parameters Table

$p(w = t|z = k)$: a multinomial distribution over terms that corresponding one of the latent topics z=k.

$p(t|z = k) = \vec{\varphi_k}$: term distribution for each topic k.

$p(z|d=m)=\vec{\vartheta_m}$: topic distribution for each document m.

$\underline{\phi}=(\vec{\varphi_k})_{k=1}^{K}$: parameter set.

$\underline{\theta}=\left(\vec{\vartheta_m}\right)_{m=1}^{M}$: parameter set.

M : number of document to generate (constant scalar).

K : number of topics (constant scalar).

V : number of terms t in vocabulary (constant scalar).

$\vec{\alpha}$: hyper parameter of Dirichlet distribution which is prior distribution of doc-topic multinomial distribution.

$\vec{\beta}$: hyper parameter of Dirichlet distribution which is prior of topic-term multinomial distribution.

N_m : length of document m.

$z_{m,n}$: topic indicator for the nth word in document m.

$w_{m,n}$: term indicator for the nth word in document m.

1.3 Mixture modelling

LDA是一种混合模型，其使用一组子分布加权来建模观察到的数据，其实也就是使用主题分布作为分量，那么每个词的概率可以表示为：

$$p(t=w)=\sum_{k=1}^{K}p(t=w|z=k)p(z=k|),\ \sum_{k=1}^{K}p(z=k)=1 \qquad (10)$$

但是LDA中的主题分布并不是全局一样的，而是基于每一篇文档主题分布情况是不同的，于是在LDA中有两组目标需要推断（1）主题k下的词分布$p(t|z=k)=\vec{\varphi}_k$和（2）文档m下的主题分布$p(z|d=m)=\vec{\vartheta}_m$。

1.4 Generative model

为了获得推断策略，LDA生成模型的过程可以被理解为如下内容：对于每一篇文档，首先生成主题分布$\vec{\vartheta}_m$，对于文档中的每个词，根据$\vec{\vartheta}_m$各主题占比分布对每个词选择一个主题，用$z_{m,n}$表示，那么根据这个词所在主题的$\vec{\varphi}_{z_{m,n}}$来生成这个词。需要注意的是$\vec{\varphi}_k$在整个语料中只会生成一次。

1.5 Likelihoods

对于整个语料集，如果每一个词都被赋予了主题标记$z_{m,n}$，那么一篇文档的似然可以表示为：

$$L(\vec{w}_m, \vec{z}_m, \vec{\vartheta}_m, \vec{\phi}) = \Pi_{n=1}^{N_m} p(w_{m,n}|\vec{\varphi}_{z_{m,n}}) p(z_{m,n}|\vec{\vartheta}_m) p(\vec{\vartheta}_m|\vec{\alpha}) p(\phi|\vec{\beta}) \tag{11}$$

对于一篇文档中的一个词，其产生的概率可以表示为(57)(12)：

$$p(w_{m,n} = t|\vec{\vartheta}_m, \underline{\phi}) = \sum_{k=1}^{K} p(w_{m,n} = t|\vec{\varphi}_k) \cdot p(z_{m,n} = k|\vec{\vartheta}_m) \tag{12}$$

对于语料$W = (\vec{w}_m)_{m=1}^{M}$，每篇文档的生成是独立的，每篇文档中的每个词生成过程也是独立的，所以语料的似然可以表示为(58)(13)：

$$L = p(W|\underline{\theta}, \underline{\phi}) = \Pi_{m=1}^{M} p(\vec{w}_m|\vec{\vartheta}_m, \underline{\phi}) = \Pi_{m=1}^{M} \Pi_{n=1}^{N_m} p(w_{m,n}|\vec{\vartheta}_m, \underline{\phi}) \tag{13}$$

1.6 Inference via Gibbs Sampling

对于包含隐含变量$\vec{z}$，其后验概率$p(\vec{z}|\vec{x})$通常是比较需要的分布，对于这样包含隐含变量模型的通用Gibbs sampler的公式可以表示如下(60)(14)公式所示：

$$p(z_i|\vec{z}_{\neg i}, \vec{x}) = \frac{p(\vec{z}, \vec{x})}{p(\vec{z_{\neg i}}, \vec{x})} \tag{14}$$

$$= \frac{p(\vec{z}, \vec{x})}{\int_Z p(\vec{z}, \vec{x}) dz_i} \tag{15}$$

其中分母如果是对离散变量，那么可以改为对离散变量求和。按照Gibbs Sampling的思路，不断根据分量的条件概率进行采样，假设我们每次采样得到的样本为$\tilde{\vec{z_r}}, r \in [1, R]$，如果采样次数足够多的话，那么隐含变量的后验概率可以表示为(61)(16)：

$$p(\vec{z}|\vec{x}) \approx \frac{1}{R} \sum_{r=1}^{R} \delta(\vec{z} - \vec{z_r}) \tag{16}$$

其中$\delta(\vec{u}) = 1 \; if \; \vec{u} = 0; \; 0 \; otherwise$。

1.7 The collapsed LDA Gibbs Sampler

为了设计出LDA的Gibbs Sampler，我们使用上面提到的隐含变量方法，在我们的模型中，隐含变量是$z_{m,n}$，也就是语料中词$w_{m,n}$相对应的主题。通过对$z_{m,n}$ *and* $w_{m,n}$进行统计，可以得到其他参数的情况。

现在我们推断的目标是$p(\vec{z}|\vec{w})$，也就是每个词对应的主题情况，如(62)(17)所示：

$$p(\vec{z}|\vec{w}) = \frac{p(\vec{z},\vec{w})}{p(\vec{w})} = \frac{\Pi_{i=1}^{W} p(z_i, w_i)}{\Pi_{i=1}^{W} \sum_{k=1}^{K} p(z_i = k, w_i)} \tag{17}$$

由于上式中的分母计算量比较大，那么这个时候Gibbs Sampling派上用场了，为了仿真$p(\vec{z}|\vec{w})$，我们根据$p(z_i|\vec{z_{\neg i}}, \vec{w})$进行Markov Chain进行Gibbs Sampling。根据公式(60)(14)，需要知道联合分布概率。

Joint Distribution. LDA中的联合分布可以分解为(63)(18)：

$$p(\vec{w},\vec{z}|\vec{\alpha},\vec{\beta}) = p(\vec{w}|\vec{z},\vec{\beta})p(\vec{z}|\vec{\alpha}) \tag{18}$$

等式(18)右边第一项可以表示为(64)(19)：

$$p(\vec{w}|\vec{z},\underline{\phi}) = \Pi_{i=1}^{W} p(w_i|z_i) = \Pi_{i=1}^{W} \varphi_{z_i,w_i} \tag{19}$$

上式是表示每个词从独立的多项分布中产生，我们可以将上面的成绩拆成两项，第一项按照主题乘积，第二项按照词汇表乘积，于是可以表示为(65)(20)：

$$p(\vec{w}|\vec{z},\underline{\phi}) = \Pi_{k=1}^{K} \Pi_{i:\ z_i=k} p(w_i = t|z_i = k) = \Pi_{k=1}^{K} \Pi_{t=1}^{V} \varphi_{k,t}^{n_k^{(t)}} \tag{20}$$

其中$n_k^{(t)}$表示词t在主题k下出现的次数。

上式表示的是在一组确定的ϕ参数下词出现的条件概率，我们知道ϕ中的参数是有Dirichlet先验的，因此将上式对ϕ进行积分或者累加，那么就能求得在超参β下的词条件概率：

$$p(\vec{w}|\vec{z},\vec{\beta}) = \int p(\vec{w}|\vec{z},\underline{\phi}) p(\underline{\phi}|\vec{\beta}) d\underline{\phi} \tag{21}$$

$$= \Pi_{z=1}^{K} \frac{\triangle(\vec{n_z} + \vec{\beta})}{\triangle(\vec{\beta})}, \vec{n_z} = \left(n_z^{(t)}\right)_{t=1}^{V} \tag{22}$$

同理按照$p(\vec{w}|\vec{z},\vec{\beta})$的推导，可以对$p(\vec{z}|\alpha)$进行类似的推导。

$$p(\vec{z}|\theta) = \Pi_{i=1}^{W} p(z_i|d_i) \tag{23}$$

$$= \Pi_{m=1}^{M}\Pi_{k=1}^{K} p(z_k = 1|d_i = m) \tag{24}$$

$$= \Pi_{m=1}^{M}\Pi_{k=1}^{K} \vartheta_{m,k}^{n_m^{(k)}} \tag{25}$$

其中d_i表示词i对应的文档，$n_m^{(k)}$表示在文档m中，topic k出现的次数。上式对θ进行积分，可以得到：

$$p(\vec{z}|\vec{\alpha}) = \int p(\vec{z}|\underline{\theta})p(\underline{\theta}|\vec{\alpha})d\underline{\theta} \tag{26}$$

$$= \Pi_{m=1}^{M}\frac{\triangle(\vec{n_m} + \vec{\alpha})}{\triangle(\vec{\alpha})}, \vec{n_m} = \left(n_m^{(k)}\right)_{k=1}^{K} \tag{27}$$

于是可以得到主题和词的联合分部表示为：

$$p(\vec{w},\vec{z}|\vec{\alpha},\vec{\beta}) = \Pi_{z=1}^{K}\frac{\triangle(\vec{n_z} + \vec{\beta})}{\triangle(\vec{\beta})}\Pi_{m=1}^{M}\frac{\triangle(\vec{n_m} + \vec{\alpha})}{\triangle(\vec{\alpha})} \tag{28}$$

Full Conditional.根据联合概率分布，对于一个词$i = (m, n)$我们可以得到其条件概率，也就是Gibbs Sampler采样一个隐含变量的条件概率，如式子(74,78)(29,30)：

$$p(z_i = k|\vec{z_{\neg i}},\vec{w}) = \frac{p(\vec{w},\vec{z})}{p(\vec{w},\vec{z}_{\neg i})} = \frac{p(\vec{w}|\vec{z})}{p(\vec{w}_{\neg i}|\vec{z}_{\neg i})p(w_i)} \cdot \frac{p(\vec{z})}{p(\vec{z}_{\neg i})} \tag{29}$$

$$\propto \frac{n_{k,\neg i}^{(t)} + \beta_t}{\sum_{t=1}^{V} n_{k,\neg i}^{(t)} + \beta_t}(n_{m,\neg i}^{(k)} + \alpha_k) \tag{30}$$

Multinomial Parameters.最终，我们需要求解多项分布的参数，这些参数用之前的参数集合(θ,ϕ) 表示。根据这些参数的定义，以及结合Dirichlet先验，根据贝叶斯公式，我们可以得到多项分布参数的后验估

计，如等式(79,80)(31,37)所示：

$$p(\vec{\vartheta}_m|\vec{z}_m,\vec{\alpha}) = \frac{p(\vec{z}_m|\vec{\vartheta}_m)p(\vec{\vartheta}_m|\vec{\alpha})}{p(\vec{z}_m|\vec{\alpha})} \tag{31}$$

$$= \frac{p(\vec{z}_m|\vec{\vartheta}_m)p(\vec{\vartheta}_m|\vec{\alpha})}{\int p(\vec{z}_m|\vec{\vartheta}_m)p(\vec{\vartheta}_m|\vec{\alpha})d\vec{\vartheta}_m} \tag{32}$$

$$= \frac{\Pi_{k=1}^{K}\vartheta_{m,k}^{n_m^{(k)}}\frac{1}{\Delta(\vec{\alpha})}\Pi_{k=1}^{K}\vartheta_{m,k}^{\alpha_k-1}}{\frac{\Delta(\vec{n}_m+\vec{\alpha})}{\Delta(\vec{\alpha})}} \tag{33}$$

$$= \frac{\Pi_{k=1}^{K}\vartheta_{m,k}^{n_m^{(k)}+\alpha_k-1}}{\Delta(\vec{n}_m+\vec{\alpha})} \tag{34}$$

$$= \frac{1}{Z_{\vartheta_m}}\Pi_{n=1}^{N_m}p(z_{m,n}|\vec{\vartheta}_m)\cdot p(\vec{\vartheta}|\vec{\alpha}) \tag{35}$$

$$= Dir(\vec{\vartheta}_m|\vec{n}_m+\vec{\alpha}) \tag{36}$$

$$p(\vec{\varphi}_k|\vec{z},\vec{w},\vec{\beta}) = \frac{1}{Z_{\varphi_k}}\Pi_{i:z_i=k}p(w_i|\vec{\varphi}_k)\cdot p(\vec{\varphi}_k|\vec{\beta}) \tag{37}$$

$$= Dir(\vec{\varphi}_k|\vec{n}_k+\vec{\beta}) \tag{38}$$

上式中$\vec{n}_m$表示第m篇文档中观察到的topic出现次数，$\vec{n}_k$则相应的表示在topic k中各词对应观察到的次数。

和(31)中的推导相似，(37)中表示的是主题下词的分布，由于φ_k是全局的，那么需要统计所有的词中，主题被标记为k的词分布情况，就能得到该主题下词的分布了，如果用w_k表示主题k下各词出现情况，于是(37)的详细推导可以如下计算：

$$p(\vec{\varphi}_k|\vec{w}_k,\vec{\beta}) = \frac{p(\vec{w}_k|\vec{\varphi}_k)p(\vec{\varphi}_k|\vec{\beta})}{p(\vec{w}_k|\vec{\beta})} \tag{39}$$

$$= \frac{\Pi_{t=1}^{V}\varphi_{k,t}^{n_k^{(t)}}\frac{1}{\Delta(\vec{\beta})}\Pi_{t=1}^{V}\varphi_{k,t}^{\beta_t-1}}{\frac{\Delta(\vec{n}_k+\vec{\beta})}{\Delta(\vec{\beta})}} \tag{40}$$

$$= \frac{\Pi_{t=1}^{V}\varphi_{k,t}^{n_k^{(t)}+\beta_t-1}}{\Delta(\vec{n}_k+\vec{\beta})} \tag{41}$$

$$= Dir(\vec{\varphi}_k|\vec{n}_k+\vec{\beta}) \tag{42}$$

根据Dirichlet Distribution的期望计算方法$< Dir(\vec{\alpha}) >= \frac{\alpha_i}{\sum_i \alpha_i}$，那么根

据(79,80) (31, 37)，可以计算得到下面的结果：

$$\varphi_{k,t} = \frac{n_k^{(t)} + \beta_t}{\sum_{t=1}^{V} n_k^{(t)} + \beta_t} \tag{43}$$

$$\vartheta_{m,k} = \frac{n_m^{(k)} + \alpha_k}{\sum_{k=1}^{K} n_m^{(k)} + \alpha_k} \tag{44}$$

2 References

1 Parameter estimation for text anaylysis.
http://www.52nlp.cn/unconstrained-optimization-one.